

Roteiro-Desafio-NLP

Processamento de Linguagem Natural com Modelos BERT para Português

Curso: DSM — Tecnologia em Desenvolvimento de Software Multiplataforma · 6º Semestre
Início: 08/05/2026 · Prazo: 1 semana
Equipes: Grupos de 3 a 5 integrantes · Google Colab (gratuito)
Recursos: [huggingface.co/Itau-Unibanco](#) · NorBERTo-base · NorBERTo-large · FAQ_BACEN

FASE 0 · PRELIMINAR

■ Leitura Crítica e Contextualização Teórica

Antes de executar qualquer notebook, o grupo realiza a leitura crítica do artigo científico base desta atividade e produz um resumo próprio — que será depois comparado com o resumo gerado pelo NotebookLM (Google). Esta fase não é apenas de leitura: é uma introdução prática ao que são os Grandes Modelos de Linguagem (LLMs) e à disciplina de NLP.

1 Leitura Crítica do Artigo

Leia o artigo 'NorBERTo: A ModernBERT Model Trained for Portuguese with 331 Billion Tokens Corpus' (PROPOR 2026 · Itau-Unibanco / ICTi). Foque na introdução, metodologia e resultados (Tabelas 7 e 8). Anote dúvidas e pontos de interesse do grupo.

2 Resumo Próprio do Grupo

Produza um resumo do artigo em até 300 palavras. O resumo deve cobrir: (a) problema abordado, (b) solução proposta (NorBERTo + Aurora-PT), (c) principais resultados nos benchmarks e (d) limitações reconhecidas pelos autores.

4 Comparação Humano × LLM ★

Compare os dois resumos explicitando diferenças de ênfase, precisão, omissões e escolhas de linguagem. Reflita: o NotebookLM é uma LLM — um sistema de NLP. O que isso revela sobre como máquinas processam e representam texto? Veja o box explicativo abaixo.

5 Ir para a Fase 1

Com o contexto teórico consolidado, o grupo está pronto para iniciar os experimentos práticos. Abra o notebook Fase1_Embeddings_Similaridade.ipynb no Google Colab e siga os passos.

★ Por que o Passo 4 vai além da leitura de texto? — NotebookLM, LLMs e NLP

O NotebookLM (Google) é uma aplicação construída sobre um Grande Modelo de Linguagem (LLM) — a mesma família de sistemas que inclui o ChatGPT, o Claude e o Gemini. Um LLM é um modelo estatístico treinado em bilhões de textos para prever e gerar sequências de palavras plausíveis, aprendendo padrões sintáticos, semânticos e factuais da linguagem humana. Ele é, em essência, o resultado aplicado de décadas de pesquisa em Processamento de Linguagem Natural (NLP) — a disciplina que este roteiro explora.

Ao comparar o seu resumo com o do NotebookLM, o grupo não está apenas avaliando qualidade textual: está observando como um sistema de NLP representa, comprime e reproduz conhecimento científico. Perguntas que guiam a reflexão: O LLM omitiu limitações que você destacou? Ele inventou algum dado numérico? Usou linguagem mais técnica ou mais acessível? Captou a contribuição do Aurora-PT? Essa comparação revela capacidades e limites reais dos LLMs — e por que saber avaliar criticamente suas saídas é uma competência essencial para qualquer profissional de tecnologia em 2026.

FASE 01 · USO DIRETO (SEM FINE-TUNING)

■ Embeddings e Similaridade Semântica

Gere embeddings com NorBERTo-base, calcule similaridade cosseno, visualize com t-SNE e faça busca semântica no FAQ_BACEN.

■ DS: FAQ_BACEN

■ ML: NorBERTo-base

01

FASE 02 · FINE-TUNING SUPERVISIONADO

■ Fine-tuning e Comparação de Modelos

Fine-tuning do NorBERTo-base em classificação de texto. Compare com BERTimbau (mesmas condições). Reporte F1, precisão, recall.

■ DS: ASSIN 2 / HateBR / TweetSentBR

■ ML: NorBERTo-base vs BERTimbau

02

FASE 03 · PIPELINE NLP COMPLETO

■ Pipeline Clássico vs Transformer

Do texto bruto ao modelo: pré-processamento → TF-IDF → sklearn → NorBERTo. Compare abordagem clássica e transformer.

■ DS: ASSIN 2

■ ML: TF-IDF + LR → NorBERTo-base

03

FASE 04 · TOKEN CLASSIFICATION

■ Reconhecimento de Entidades (NER)

Identifique pessoas, organizações, datas e valores em textos do

FAQ_BACEN. Compare spaCy vs BERT NER com visualização colorida.

■ DS: FAQ_BACEN · Textos jornalísticos

■ ML: spaCy lg + BERT NER

04

FASE 05 · RAG: RETRIEVER + GERADOR

■ Sumarização + Busca Semântica (RAG)

NorBERTo como retriever semântico com FAISS. Integre LLM API para respostas fundamentadas. Avalie com MRR@10.

■ DS: FAQ_BACEN · Aurora-PT

■ ML: NorBERTo-base + LLM API

05

■ AVALIAÇÃO: 10 questões de múltipla escolha ao final

■ 6 Notebooks Colab

■ 5 PPTs Gabarito

■ HuggingFace Itau-Unibanco

■ Artigo NorBERTo PROPOR 2026